

令和4年度 卒業論文

インナーの口コミ感情分類精度向上と市場分析

—BERT-CNN とロジスティック回帰分析—

慶應義塾大学理工学部 管理工学科4年

学生番号 61902358

岩本陸

目次

1. 序論.....	4
1.1 研究背景	4
1.2 研究目的	4
1.3 論文構成	5
2. インナー市場	6
3. 理論.....	8
3.1 BERT-CNN.....	8
3.1.1 BERT とは.....	8
3.1.2 Transformer Encoder	9
3.1.3 CNN とは	11
3.1.4 BERT-CNN とは.....	12
3.2 ロジスティック回帰.....	13
3.2.1 ロジスティック回帰とは.....	13
3.2.2 訓練とコスト関数.....	14
3.2.3 回帰係数とオッズ比	15
3.3 TF-IDF	15
3.4 XGBoost	15
3.4.1 XGBoost とは	16
3.4.2 正則化された目的関数	16
3.4.3 決定木の作成	16
3.4.4 過学習対策.....	17
3.4.5 特徴量重要度	18
4. データセット	19
4.1 データ概要	19
4.2 基礎集計	19

4.2.1	男女比の確認	19
4.2.2	口コミ評価の確認.....	20
4.3	前処理.....	21
4.3.1	口コミラベルについて	21
4.3.2	不均衡データの処理	22
5.	実験・分析.....	22
5.1	インナーの口コミ感情分類精度向上	23
5.1.1	BERT-CNN 感情分類	23
5.1.2	既存感情分類器との比較.....	23
5.1.3	考察.....	24
5.2	インナーの市場分析.....	25
5.2.1	強み・弱み分析	25
5.2.2	アンケート調査分析	27
5.2.3	考察.....	32
6.	結論.....	34
6.1.1	本研究の結論	34
6.1.2	今後の展望.....	34
7.	謝辞.....	36
8.	参考文献	37

1. 序論

1.1 研究背景

近年、ソーシャルメディアの普及やネットショッピング利用の増加に伴い、商品や企業に対する口コミは重要視されている。三菱 UFJ リサーチ&コンサルティングが2018年9月に発表した「口コミサイト・インフルエンサーマーケティングに関するアンケート結果」によると、商品やサービスを購入するときに情報源として口コミを重要視している人は46.5%、Instagram や Twitter といった SNS を重視していると回答した人は38.1%である。また、34.4%の人が「初めての商品やサービスを購入する際に必ず口コミを確認する」と回答し、「確認することの方が多いい」は50%であり、合計すると80%以上の人が商品やサービスを購入する際に口コミを参考に行っていることが明らかとなった[1]。このような状況下、口コミが全くない商品は人気がない商品とみなされる可能性があり、良質な口コミを生成させることが非常に重要である。ユーザーの生の声を聞ける貴重な口コミから企業の改善に活かすためには、口コミの分析は必要不可欠である。

アパレル市場最大手である UNIQLO は、自社 EC サイトでの販売に力を入れており、2020 年 9 月から 2021 年 8 月までの期間において、アパレル EC の売上高ランキングで 1 位を獲得している。決算情報によると、2021 年 8 月期の EC の売上高は 1269 億円、前年比 17.9%増と大幅に上昇している[2]。オンラインにしかない限定商品を用意したり、店舗で適したサイズが見つからない場合は、EC サイトでの購入を促したり、さらに EC サイトで購入した製品の店舗受取を可能にするなどオムニチャネル施策により利便性を高めている。その一方で、2017 年に 1 億枚以上売り上げたインナーウェアが 2021 年には 7263 万枚に減少しているという現状がある。この現状下で、共同研究企業である東レ株式会社は、UNIQLO の EC サイトに集まった数多くの口コミを利用して、直接言語に現れていないような顧客の潜在ニーズを掴み、売上向上に繋げるという課題がある。

1.2 研究目的

本研究における目的は2点ある。1点目は、口コミ感情分類精度の向上である。2点目は、インナーウェア市場分析による、複数のインナーウェア企業の比較と、顧客の潜在ニーズの発掘である。

1点目に関しては、口コミのポジティブ・ネガティブの感情分類を正確に行うことは、口コミを活用する上で必要不可欠である。その一方で、提供された UNIQLO のデータでは、口コミに対するネガティブ・ポジティブのラベルが付けられているにも関わらず、正確性に欠けるという課題がある。そこで、感情分類精度の向上は、これからの口コミ分析をするための基盤として、非常に重要であると考えられる。

2点目に関しては、1.1節でも述べた通り、口コミはユーザーの生の声であるため、顧客の潜在ニーズを掴む上で重要なデータである。顧客のニーズには「顕在ニーズ」と「潜在ニーズ」の2種類が存在する。「顕在ニーズ」とは、顧客が自身のニーズを自覚している状態のことで、「潜在ニーズ」とは自覚していない状態のことを指す。顕在ニーズを把握することは、「が欲しい」など言語に表れるニーズであるため、比較的簡単に把握することができるが、顕在ニーズだけをベースにした商品を紹介しても、顧客にヒットしない場合もある。そこで、言語からだけではわからない潜在ニーズを発掘することは、売上を向上させる上で重要であると考えられる。そこで、複数のインナーウェア業界の企業の口コミを分析し、インナーウェアに対する潜在ニーズを発掘することは、インナーウェア業界において非常に有効であると考えられる。

以上2点を本研究の目的とする。

1.3 論文構成

本論文の構成は以下の通りである。第2章では研究対象であるインナーウェア市場について説明を行う。第3章では本研究で用いた自然言語処理モデルである BERT-CNN、自然言語のベクトル表現手法である tf-idf、機械学習手法であるロジスティック回帰、XGBoost について説明を行う。第4章では本研究の分析に用いたデータの概要や前処理について説明を行う。第5章では本研究で行った分析結果とそれに対する考察について説明を行う。第6章では本研究の結論と今後の展望について述べる。

2. インナー市場

株式会社矢野経済研究所は、国内のレディースインナーウェア、メンズインナーウェア小売市場を調査し、製品セグメント別の動向、参入企業動向、将来展望を明らかにした。2021年のインナーウェア小売市場規模はレディースで前年比 101.3%の 5,580 億円、メンズで前年比 101.0%の 2,300 億円とプラスへと転じた。前年まで9年連続の市場縮小となっていたが、2020年の大幅な落ち込みからの反動によるものと推察される。2021年も新型コロナウイルス感染症に関する様々な制限、コロナ禍による生活様式の変化があったため、インナーウェアの需要が回復するような動きが見えづらく、2020年当時のような都心部を中心とした商業施設や百貨店の休業・時短営業は緩和されたが、実店舗における「コロナ前の活況」にはまだ届いていないのが現状である[3]。しかし、ECサイトによる売上によって大ダメージを免れたインナー企業も存在する。トリンプ・インターナショナル・ジャパンによると、全社売上高のうち約15%をECが占め、売上高の占有率も上昇傾向にあると発表している[4]。このようにコロナ禍であってもECによって売上を上げている下着企業も多く存在し、その一方でECへの準備ができていない下着企業はコロナによる経済的ダメージを受けていることが多く見られる。コロナ禍でもECサイトなどにより成功を収める企業もあるインナー業界であるが、時代と変わりつつある顧客のニーズに合わせた商品転換が今後の課題である。

以下にインナーウェアの代表的な2つの企業の特徴について説明する。現在、価格が高くても機能性のある高付加価値商品には消費者のニーズが集まり、節約と贅沢のメリハリを効かせた選別消費の傾向が強まっている。肌着は大手カジュアル衣料や量販店プライベートブランドの人氣が高い。夏は涼しさや臭い・汗を抑える通気・吸水性、冬は発熱をうたった断熱・防寒性に優れた肌着が主流だ。ファーストリテーリングの傘下のUNIQLOの「エアリズム」「ヒートテック」は機能性肌着として定番化した。男女とも着用が目立たないシームレスタイプが定着している。着心地を追求した商品も注目される。ブラジャーでは柔らかいワイヤーを使った「第3のブラ」に続き、ワイヤー入りブラと同程度のサポート力を持ち機能性と快適性に優れた「ノンワイヤーブラ」の投入が相次ぐ。かつては中高年向けと考えられたが、UNIQLOの「ワイヤレスブラ」や「ブラトップ」が若年層に支持されるなど、需要の裾野が広がっている[5]。

GUNZEは、大阪市に本社を構えるメンズの下着をメインとする繊維メーカーである。肌着や下着のシェアでは日本国内で確固たる地位を築いている大手繊維メーカーである。GUNZEは、男性向け、女性向けを問わずあらゆる衣類を展開している。その中にはルームウェアも含まれて

おり、根強い人気を誇っている。GUNZE の特徴は、まずブランドの多さが挙げられる。メインブランドの「グンゼ」だけでなく、高品質な高級ライン「THE GUNZE」、日本の夏の風物詩である「クールビズ」の語源となった「COOLBIZ」、若年層に高い人気を誇る「BODY WILD」、アシックスと共同開発した「カラダトレーナー」など多くのブランドを抱えている。GUNZE のルームウェアもいくつかのブランドから展開されている。GUNZE のルームウェアの特徴は、多種多様な種類である。様々な種類のデザイン素材によるルームウェアの多様な展開が特徴である[6].

3. 理論

本章では、本研究で用いた分析手法の理論について述べる。本章は、[8][9]エラー! 参照元が見つかりません。を参考にした。

3.1 BERT-CNN

本節ではインナーのロコミ感情分類精度向上に用いた BERT-CNN について述べる。

3.1.1 BERT とは

BERT は 2018 年 10 月に Google の Jacob Devlin らの論文で発表された自然言語処理モデルである[11]。BERT は様々な自然言語処理タスクにおいて当時の最高スコアを叩き出した。BERT は Bidirectional Encoder Representations from Transformers の略で、Transformer の Encoder を使っており、文章を双方向から学習することにより「文脈を読むこと」が実現した。BERT の概要は事前学習、ファインチューニングの 2 段階がある。

事前学習では、ラベルなしデータを用いて複数のタスクで文章から表現を学習する。Masked Language Model と Next Sentence Prediction という 2 つの手法を同時進行で行うことで学習する。Masked Language Model は、入力 of 15% の単語を確率的に別の単語で置き換え、文脈から置き換える前の単語を予測させる。BERT は双方向の Transformer によって学習するため、従来の手法に比べ精度が向上したが、それを実現しているのが Masked Language Model である。Next Sentence Prediction は文の片方を 50% の確率で他の文に置き換え、それらが隣り合っているか否かを判別することによって学習する。これにより 2 つの文の関係性を学習でき、より広範的な自然言語処理モデルとして機能できる。

ファインチューニングでは、事前学習の重みを初期値としてラベルありデータを用いてあるタスクに特化するように学習を行う。新たに加えられた分類器のパラメータにはランダムな値を与え、ラベル付データを用いて BERT と分類器の両方のパラメータを学習する。事前学習で得られたパラメータを初期値として使うことで、比較的少数の学習データからでも高い性能のモデルを得ることができる。




図 3-1 : BERT の概略図

3.1.2 Transformer Encoder

BERT は Transformer というモデルで提案された Transformer Encoder を用いている。Transformer Encoder は Attention を用いたニューラルネットワークで、Transformer Encoder のそれぞれの層は、主に Multi-Head Attention と Feedforward Network から構成される。




図 3-2 : Transformer Encoder の概略図

Multi-Head Attention の構成要素である Scaled Dot-Product Attention を説明する。 n 個のトークンで構成される文章を処理することを考える。 i 番目のトークンに対応する出力は x_i で与え

られるとする．それぞれの出力に対し，行列 W^Q, W^K, W^V で線形変換を行うことにより，クエリ q_i ，キー k_i ，バリュー v_i と呼ばれる3つの d 次元ベクトルを準備する．

$$q_i = x_i W^Q \quad (1)$$

$$k_i = x_i W^K \quad (2)$$

$$v_i = x_i W^V \quad (3)$$

Scaled Dot-Product Attention では，これらのベクトルの組を入力として受けそれぞれのトークンに対しベクトル a_i を出力する．ここで a_i はバリュー v_i の重み付き平均で与えられる．

$$a_i = \sum_{j=1}^n a_{i,j} v_j \quad (4)$$

重みは i 番目のトークンを処理する際に， j 番目のトークンの情報を重視する度合いを表す．この重みは，キーとクエリから決まる．Transformer では，Scaled Dot-Product と呼ばれる方法でクエリとキーのスコアを評価する． q_i と k_j の内積を \sqrt{d} で割って得られる $\hat{a}_{i,j}$ をスコアとして用いる．ここで d はベクトルの次元を表している．

$$\hat{a}_{i,j} = \frac{q_i \cdot k_j}{\sqrt{d}} \quad (5)$$

スコア $\hat{a}_{i,1}, \hat{a}_{i,2}, \dots, \hat{a}_{i,n}$ に Softmax 関数を適用することで，最終的に重み $\alpha_{i,1}, \alpha_{i,2}, \dots, \alpha_{i,n}$ を得る．

$$[\alpha_{i,1}, \alpha_{i,2}, \dots, \alpha_{i,n}] = \text{Softmax}(\hat{a}_{i,1}, \hat{a}_{i,2}, \dots, \hat{a}_{i,n}) \quad (6)$$

一つの行列演算で効率よく計算すると以下のように計算することができる．

$$X = \text{vstack}(x_1, x_2, \dots, x_n) \quad (7)$$

$$Q = \text{vstack}(q_1, q_2, \dots, q_n) \quad (8)$$

$$K = \text{vstack}(k_1, k_2, \dots, k_n) \quad (9)$$

$$V = \text{vstack}(v_1, v_2, \dots, v_n) \quad (10)$$

$$A = \text{vstack}(a_1, a_2, \dots, a_n) \quad (11)$$

$$A = \text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \quad (12)$$

と表現される．

Transformer Encoder では，Scaled Dot-Product Attention を拡張した Multi-Head Attention が用いられる．Multi-Head Attention は，クエリ，キー，バリューの組を複数用意しておき，それぞれの組に対して Scaled Dot-Product Attention を適用し，最後に出力を一つに集約する方法である．

Multi-Head Attention はそれぞれのトークンに対し、ベクトル x_i を a_i に変換する。Transformer Encoder では Residual Connection が用いられており、Multi-Head Attention の出力そのものではなく、入力と出力の和である以下を次の処理に送る。

$$y_i = x_i + a_i \quad (13)$$

Residual Connection により深い層を持つモデルに対しても、学習が適切に行える効果がある。

Layer Normalization は、次の処理への入力を正規化するものである。ベクトル y_i が与えられた時、その要素の平均 μ_i と標準偏差 σ_i を用いて以下のように出力する。

$$LayerNorm(y_i) = \frac{\gamma}{\sigma_i} \odot (y_i - \mu_i) + \beta \quad (14)$$

ここで β と γ はパラメータであり、 y_i と同じ次元のベクトルである。Layer Normalization により学習が早く収束することが期待される。

Transformer Encoder の後半では、Feedforward Network により処理される。それぞれのトークンに対応するベクトルを z_i と置くと、以下のように表現される。

$$FFN(z_i) = GELL(x_i W_1 + b_1) W_2 + b_2 \quad (13)$$

GELL 関数は、ReLU 関数を滑らかにしたような関数である。この後に Residual Connection と Layer Normalization を適用したものが、Transformer Encoder の層の出力となる。

3.1.3 CNN とは

CNN[12] は Convolutional Neural Network の略で、いくつもの深い層を持ったニューラルネットワークであり、主に画像認識の分野において価値を生むネットワークである。CNN は「畳み込み層」と「プーリング層」といった個性的な機能を備えた層を積み上げることで構成されている。現在は様々な分野で活用されている。

畳み込み層では、フィルタと呼ばれる重みを用いて画像の特徴を抽出する。フィルタを画像の左上から順に重ね、画像とフィルタの値を掛け合わせる。掛け合わせた数値の総和を求め、特徴量マップという新たな二次元データを取得する。

プーリング層は、計算の負荷、メモリ使用量、パラメータ数の削減のために入力画像をサブサンプリングすることにある。プーリング層のニューロンには重みはなく、max や mean といった集計関数を使って入力を集計するだけである。プーリング層では、最大値プーリング(max pooling)が最もよく利用される。

一般的な CNN モデルは、いくつかの畳み込み層を積み上げ、次にプーリング層、さらにいくつかの畳み込み層、別のプーリング層を積み上げていく形である。画像はニューラルネットワークを進むうちに徐々に小さくなるが、畳み込み層のおかげで一般にどんどん特徴量マップも増えていく。最後には、いくつかの全結合層から構成される通常の前進するニューラルネットワークが追加される。そして最後の層が予測結果を出力する。

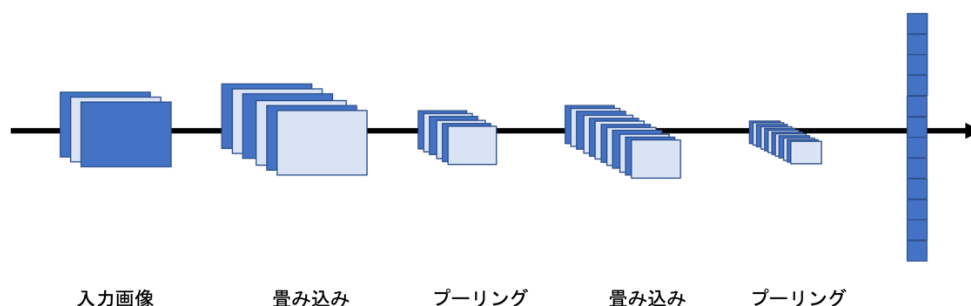


図 3-3 : CNN アルゴリズム

3.1.4 BERT-CNN とは

BERT-CNN とは、「A BERT-based Transfer Learning Approach for Hate Speech Detection in Online Social Media」[10]により提案された BERT に CNN 層を挿入したモデルである。この先行研究では、Twitter のデータセットに対し、人種差別、性差別、どちらでもない、の分類を行うにあたり、より良い精度で分類できるモデルを開発することが目的である。BERT-CNN は、通常の BERT のように最新の Transformer Encoder の出力を使用するのではなく、全ての Transformer Encoder の出力を使用する。そのため、各変換エンコーダーの出力は連結され行列が生成される。畳み込み出力には最大プーリングが適用し、各変換エンコーダーの最大値を生成する。これらの値を連結することで、完全連結ネットワークの入力となる行列が生成される。入力に Softmax 関数を適用することで、分類演算が行われる。

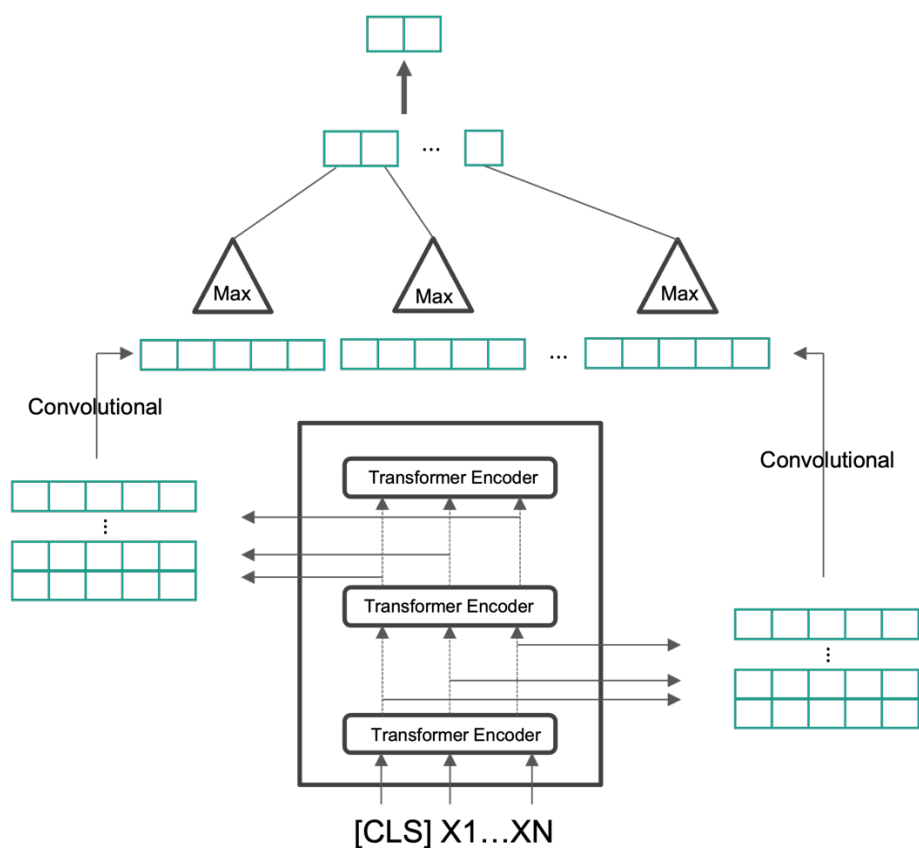


図 3-4 : BERT-CNN モデル概要

この先行論文[10]によると，CNN ベースの微調整戦略を用いて，BERT モデルの異なる変換エンコーダー層に埋め込まれた構文情報及び文脈情報を活用することで，基本の BERT よりも優れた精度で分類することができることが示されている。

本研究では、この先行論文で提案された BERT-CNN を日本語でも利用できるよう事前学習と前処理を修正し、日本語に対応したモデルを利用した。

3.2 ロジスティック回帰

本節では、主としてインナーの市場分析を行うために用いたロジスティック回帰モデル[13]について述べる。

3.2.1 ロジスティック回帰とは

ロジスティック回帰は，インスタンスが特定のクラスに属する確率を推計するためによく利用される．推計された確率が 50%以上なら，そのクラスに属すると予測し，そうでなければそ

のクラスに属しないと予測する。ロジスティック回帰モデルは、線形回帰モデルと同様に、入力特徴量の加重総和にバイアス項を加えたものを計算するが、線形回帰モデルのように計算結果を直接出力するのではなく、結果のロジスティックを返す。ロジスティックは、0 から 1 までの値を出力するシグモイド関数である。与えられたデータベクトルを \mathbf{x} 、重みを $\boldsymbol{\theta}$ とすると、以下のよう

$$p(Y = 1) = L(\mathbf{x}) = \frac{1}{1 + \exp(-\boldsymbol{\theta}^T \cdot \mathbf{x})} \quad (14)$$

シグモイド関数の挙動を以下の図に示す。




図 3-5：シグモイド関数

そしてロジスティック回帰モデルによる予測は以下のように行う。

$$\hat{y} = \begin{cases} 0 & \text{if } L(\mathbf{x}) < 0.5 \\ 1 & \text{if } L(\mathbf{x}) \geq 0.5 \end{cases} \quad (15)$$

3.2.2 訓練とコスト関数

訓練の目的は、モデルが陽性インスタンスに対して高い確率、陰性インスタンスに対して低い確率を推計するようにパラメータ $\boldsymbol{\theta}$ を設定することである。訓練セット全体に対するコスト関数は、単純に全ての訓練インスタンスのコストの平均である。これを Log Loss と呼ばれる一つの式で書くことができる。

$$J(\boldsymbol{\theta}) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)})] \quad (16)$$

このコスト関数を最小にするようにパラメータ $\boldsymbol{\theta}$ を決定する。

3.2.3 回帰係数とオッズ比

ロジスティック回帰の結果を解釈する上で重要な統計値として、回帰係数とオッズ比が挙げられる。回帰係数は変数が1変化したときに確率変動する程度のことである。絶対値が大きいほど変数が1変化したときに及ぼす影響が大きいと考えられる。

続いてオッズ比である。オッズとは、ある事象が起こる可能性で、発生しない確率に対する発生する確率の比率である。

$$odds = \frac{p(Y=1)}{1-p(Y=1)} \quad (17)$$

オッズは0から ∞ の値が得られ、オッズが1より大きいと発生する確率が発生しない確率より大きいことを、逆に1より小さいと発生しない確率が発生する確率より大きいことを意味する。また、オッズが1になると自傷の発生する確率と発生しない確率が等しくなる。一方オッズ比とは、二つのオッズの比率であり、目的変数の影響力を示す指標である。オッズ比の値が大きいほど、その説明変数によって目的変数が大きく変動することを意味する。

3.3 TF-IDF

tf-idfは、特徴量がどの程度情報を持っていそうかに応じて、特徴量のスケールを変換する方法である。本研究では、インナーの市場分析において口コミを数値化する際に用いた。

この手法は、特定の文書にだけ頻繁に現れる単語に大きな重みを与え、コーパスの中の多数の文書に現れる単語にはあまり重みを与えない。特定の文書にだけ頻出し、他の文書にはあまり現れない単語は、その文書の内容をよく示しているのではないかという発想から生まれた手法である。文書 d における、単語 w のtf-idfスコアは以下のように与えられる。

$$tfidf(w, d) = df \left(\log \left(\frac{N+1}{N_w+1} \right) + 1 \right) \quad (18)$$

ここで N は訓練セット中の文書の数、 N_w は訓練セットの中の w が現れる文書の数、 $tf(term\ frequency)$ は対象の文書 d 中に w が現れる回数を示している。

3.4 XGBoost

本節では、インナー市場分析の結果から特徴量重要度による顧客の潜在ニーズの発掘のために用いたXGBoost[14]について述べる。

3.4.1 XGBoost とは

XGBoost は、決定木によるブースティングにより作成される。Boosting は、複数の学習器をまとめて一つのモデルとするアンサンブル学習の一つである。一つ一つは高い精度が出ない弱い学習器であっても、誤差を改善するように弱い学習器を追加していき、それらをまとめて一つのモデルにすることで精度を上げる手法である。決定木農地回帰木という種類のものを使用する。分類であっても回帰木を使い予測値を予測確率に変換して使用する。決定木を逐次的に学習させていく。 m 番目の木を学習させる際には、 $m - 1$ 番目の木までの予測の誤差を補正するように、 m 番目の木を決定する。

レコード数を N 個、決定木は M 個あるものとして、レコードの添字は i 、決定木の添字は m で表して説明すると、XGBoost の流れは次のようになる。決定木を M 本作成していく。決定木は、分岐の作成を繰り返すことで作成する。分岐を作成するためには、どの特徴量のどの値で分岐させるかを選ぶ必要がある。どの特徴量のどの値で分岐させるかは、基本的に全ての候補を調べて、分岐させて最適な葉のウェイトを設定した時の目的関数の減少が最も大きいものとする。決定木が作成されると、その決定木に基づいて予測値を更新する。

3.4.2 正則化された目的関数

目的変数を y_i 、予測値を \hat{y}_i とした時の目的関数を $l(y_i, \hat{y}_i)$ とする。それぞれの決定木を f_m とした時、決定木に対して罰則が計算される正則化項を $\Omega(f_m)$ とする。 T を木の葉の数、 j を葉の添字、 w_j を葉のウェイトとすると、正則化項 $\Omega(f_m) = \Gamma T + \frac{1}{2} \lambda \sum_j w_j^2 + \alpha \sum_j |w_j|$ となる。すると、目的関数 L は以下の式で表される。

$$L = \sum_{i=1}^N l(\hat{y}_i, y_i) + \sum_{m=1}^M \Omega(f_m) \quad (19)$$

上記のような正則化により、モデルが必要以上に複雑になることを防ぐ。

3.4.3 決定木の作成

それぞれの決定木は、1つの葉から始めて分岐を繰り返すことにより作成する。勾配を使って決定木の分岐をどう行うかを定める。勾配を使う最適化手法のうち、勾配降下法では勾配のみ利用するが、XGBoost ではニュートン法のように勾配に加えて二階微分の値も利用する。

どの特徴量で分岐させるか、どの値により大小で分岐させるかを定めると、分岐先の葉に含まれるデータの集合が得られる。ここで、それらに与えるべき最適なウェイトとその時の目的関数の変化を求める。それまでの決定木による予測値が \hat{y}_i に与えられているとする。分岐を定めた時

のあるレコードの集合を I_j ，ウェイトを w_j とすると，そのレコードの集合の目的関数の和は以下になる．

$$L_j = \sum_{i \in I_j} l(y_i, \hat{y}_i + w_j) \quad (20)$$

これを直接最適化するのには難しいため，二次近似する．それぞれのレコードにおいて，目的関数を二次関数として近似し，その和を最適化することになる．それぞれのレコードの予測値 \hat{y}_i の周りにおける勾配 $g_i = \frac{\partial l}{\partial \hat{y}_i}$ ，二階微分値 $h_i = \frac{\partial^2 l}{\partial \hat{y}_i^2}$ とすると，目的関数の和は以下のように表される．

$$\tilde{L}_j = \sum_{i \in I_j} \left(l(y_i, \hat{y}_i) + g_i w_j + \frac{1}{2} h_i w_j^2 \right) \quad (21)$$

定数となる部分 $l(y_i, \hat{y}_i)$ は，どのようにウェイトを定めるかに影響しないため取り除く．

$$\tilde{L}'_j = \sum_{i \in I_j} \left(g_i w_j + \frac{1}{2} h_i w_j^2 \right) \quad (22)$$

この式から計算すると，目的関数 \tilde{L}'_j を最小にするウェイト w_j 及びその時の値は以下のようになる．

$$w_j = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i}, \quad \tilde{L}'_j = -\frac{1}{2} \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i} \quad (23)$$

あらかじめ g_i や h_i を求めておくと，この式を用いて，ある集合が与えられた時の目的関数の値を求めることができる．そこから，分岐を行なった時の目的関数の減少も求めることができる．つまり，分岐前の集合の目的関数を \tilde{L}'_j ，分岐後の左の葉と右の葉の目的関数を $\tilde{L}'_{jL}, \tilde{L}'_{jR}$ とすると分岐による目的関数の現象が $\tilde{L}'_j - (\tilde{L}'_{jL} + \tilde{L}'_{jR})$ という式で求められる．

3.4.4 過学習対策

XGBoost における主な過学習対策としては，学習率，サンプリング，データ数が少ない葉を構成しない，決定木の深さ制限の4つが挙げられる．

学習率に関しては，上記で求めた最適なウェイトまで一気に予測値を補正してしまうと，過学習を招いてしまう．従って，各決定木において求めたウェイトの一定割合を実際には適用し，少しずつ補正していく．

続いてサンプリングについてである。それぞれの木を作るとき、特徴量の列をサンプリングする。また、それぞれの木を作るときに、学習データの行もサンプリングする。これらの割合はパラメータで指定することができる。

データが少なすぎる葉を構成しないようにすることでも過学習を抑えることができる。葉を構成するために最低限必要となる二階微分値の和をパラメータで指定でき、下回る場合には葉は分割されない。ここで二階微分値が出てくるのは、分岐やウエイトを決める計算で重要な役割を果たしているからである。

決定木の深さを制限することでも抑制することができる。木の深さの最大値をパラメータで制限することができ、デフォルトの深さの最大値は6である。深くすると複雑なモデルとなり、よりデータの性質をよく表現できる可能性があるが、その一方で過学習しやすくなる。

3.4.5 特徴量重要度

XGBoost の特徴量重要度は、ある特徴量がどれくらい重要であるかを実数で表したものである。ジニ重要度としても知られている。ノードの不純度の減少分の重み付き和を決定木全体に渡って平均した値である。ある不純度を $I(t_p)$ 、その左右の子ノードの不純度を $I(t_L), I(t_R)$ とし、それぞれのノードのサンプル数を n_p, n_L, n_R とする($n_p = n_L + n_R$)。この時、ノード t_p の不純度の減少分の重み付き和は以下ようになる。

$$\Delta I(t_p) = \frac{n_p}{N} I(t_p) - \frac{n_L}{N} I(t_L) - \frac{n_R}{N} I(t_R) \quad (24)$$

ここで、 N はサンプル数。この値を決定木全体に渡って平均したものが特徴量重要度となる。これを $M(t_p)$ とすると、以下のようになる。

$$M(t_p) = \frac{\Delta I(t_p)}{\sum_p^{all\ nodes} \Delta I(t_p)} \quad (25)$$

なお、分母分子で N が共通であるため、式(24)において N で割らずに計算しても結果は同じになる。以上から、特徴量重要度の計算は以下の手順となる。

- 1 決定木の葉ノードを除く各ノードについて以下を計算
 - 1.1 ノードの不純度とサンプル数を掛けた値(wl)を計算
 - 1.2 ノードの wl から、左右の子ノードの wl を減じた値 g を計算
- 2 決定木全体の g の合計でこれを除した値を、そのノードの分割基準となった特徴量の特徴量重要度とする。

4. データセット

本章では、分析をするにあたり使用したデータの概要、データの収集方法、基礎集計結果、分析を行う上でのデータの前処理・整形について述べる。

4.1 データ概要

本研究で分析の対象としたデータは、共同研究企業の東レから提供された UNIQLO のインナーウェアに対する口コミデータと、Web スクレイピングにより収集した大手インナーウェア企業である GUNZE、ベルメゾン、ニッセンの3社のインナーウェアに対する口コミデータの計4社の口コミデータである。3社の収集源は、それぞれの企業の EC サイト[15][16][17]と、Amazon[18]である。スクレイピングでは、口コミ、性別、各口コミの星の数を収集した。データの詳細は表 4-1 に示す通りである。

表 4-1 データセット概要

企業名	件数	内容
UNIQLO	26,628	分析対象企業の東レから提供
GUNZE	5,492	GUNZE の EC サイト+Amazon からスクレイピング
ベルメゾン	503	Amazon からスクレイピング
ニッセン	4,730	ニッセンの EC サイト+Amazon からスクレイピング

4.2 基礎集計

本節では基礎集計の結果とその結果からどのようにポジティブ・ネガティブのラベル付を行ったかを示す。

4.2.1 男女比の確認

株式会社ハー・ストーリィは 2001 年から「クチコミと広告・宣伝」についての調査を実施し続けている。この調査によると口コミの量は女性の方が多くなる。1 日に発する単語は女性の方が男性の約 3 倍多く、口コミを広げるのは男性よりもコミュニケーション量が多い女性の方であるという結論を出しており、本論文のデータセットでも口コミの男女比を確認した。




図 4-1：各企業の男女比(上から UNIQLO,GUNZE, ベルメゾン, ニッセン)

明らかに女性の口コミが多く、UNIQLO では約 3:1, ベルメゾン, ニッセンでは全て女性の口コミであった。一方, GUNZE では, 男性の方が多い結果となった。

4.2.2 口コミ評価の確認

口コミに対し, ポジティブ・ネガティブのラベル付を行うことで, 感情分類が行えるようになる。東レのデータに関しては, 既にポジティブ・ネガティブのラベル付が行われているが, スクレイピングによる取得データは, Amazon などの EC サイトによくある星 5 個中いくつかの星であるかという評価がされている。従ってまずは, スクレイピングデータの星の数の分布を確認した。

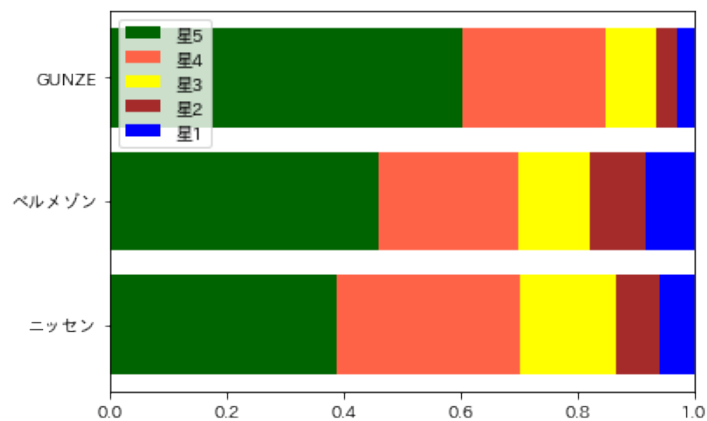


図 4-2：口コミの評価値の確認(上から UNIQLO, GUNZE, ベルメゾン, ニッセン)

表 4-2：企業ごとの口コミに対する評価件数

企業名	評価	件数
UNIQLO(東レ)	ポジティブ	25892
	ネガティブ	586
GUNZE	星 5	3248
	星 4	1327
	星 3	462
	星 2	186
	星 1	165
ベルメゾン	星 5	227
	星 4	117
	星 3	60
	星 2	48
	星 1	41
ニッセン	星 5	1773
	星 4	1461
	星 3	753
	星 2	338
	星 1	279

図 4-2 から分かるように評価が高い口コミが多い。UNIQLO では 97.8%がポジティブな口コミで、GUNZE では星 4,5 の口コミが合わせて 84.9%、ベルメゾンでは 69.7%、ニッセンでは 70.2%であった。

4.3 前処理

本節では、分析を行う前に行なったデータの前処理について述べる。

4.3.1 口コミラベルについて

4.2 節でも述べたようにスクレイピングにより取得したデータは、星の数で評価されている。分析では、ポジティブ・ネガティブの感情分類を行うため、そのラベル付を行う必要がある。本研究では、星 1, 2, 3 をネガティブ、星 5 をポジティブとして、星 4 の口コミは分析に利用しないこととした。

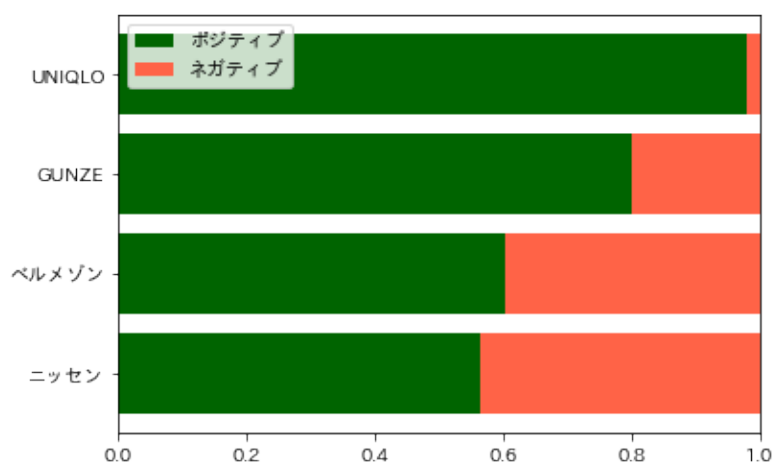


図 4-3：ポジティブ・ネガティブラベル比率(UNIQLO, GUNZE, ベルメゾン, ニッセン)

図 4-3 より，どの企業においても比率はポジティブの方が高く，不均衡データとなっていることが分かった．

4.3.2 不均衡データの処理

4.3.1 項よりポジティブ・ネガティブのデータが不均衡になっていることが分かった．不均衡データは，少数ラベルについて精度良く予測することが困難であるという問題点がある．従って，アンダーサンプリングを行うことで，多数派のデータを削除し少数派のデータ数に合わせることを行なった．以下にその結果を示す．

表 4-3：アンダーサンプリング後のデータ

企業名	評価	件数
UNIQLO	ポジティブ	586
	ネガティブ	586
GUNZE	ポジティブ	813
	ネガティブ	813
ベルメゾン	ポジティブ	149
	ネガティブ	149
ニッセン	ポジティブ	1370
	ネガティブ	1370

5. 実験・分析

本研究の目的は、インナーの口コミ感情分類精度の向上と、インナーウェア市場分析である。本章では、この2点の目的を達成するための実験・分析方法とその結果を示す。

5.1 インナーの口コミ感情分類精度向上

本節では、目的の一つであるインナーの口コミ感情分類精度の向上のために行なった実験とその結果を示す。実験方針としては、3章で述べた BERT-CNN と従来の自然言語処理モデルとの分類精度の比較を行い、更に東レのデータのラベルと、BERT-CNN による予測ではどちらが正確に分類できていたかの検証を行なった。

5.1.1 BERT-CNN 感情分類

BERT-CNN による感情分類を行うにあたり、事前トレーニング済みの日本語 BERT モデルを利用した。東北大学の乾研究室によって作成されたもので、日本語版 Wikipedia でトレーニングされたモデルである。BERT-CNN と従来の自然言語処理モデルである、tf-idf+ロジスティック回帰, BERT の分類精度比較を行なった結果を以下に示す。それぞれの手法でそれぞれの企業に対し5回実験を繰り返し、結果の AUC の平均と分散の比較を行なった。

表 5-1 : AUC 5 回平均値の比較

	UNIQLO	GUNZE	ベルメゾン	ニッセン
tfidf+ロジスティック回帰	0.808	0.852	0.698	0.861
BERT	0.988	0.943	0.876	0.961
BERT-CNN	0.993	0.955	0.810	0.962

表 5-2 : AUC 5 回の分散の比較

	UNIQLO	GUNZE	ベルメゾン	ニッセン
tfidf+ロジスティック回帰	0.0149	0.0128	0.0475	0.0310
BERT	0.00563	0.0102	0.0484	0.0181
BERT-CNN	0.000447	0.00554	0.0410	0.00259

AUC の 5 回平均は、BERT-CNN がほとんどの企業において最も高い値を示した。AUC の 5 回の分散に関しても BERT-CNN が最も小さい値を示した。

5.1.2 既存感情分類器との比較

分析対象企業の東レでは、アクセンチュア社と開発した AI によりインナーの口コミ感情分類を行なっているが、精度が非常に高いわけではないという課題があった。そこで、本研究で説明

した BERT-CNN の分類結果と東レのデータのラベルを比較し、どちらが正確に分類できているかを検証した。BERT-CNN による分類を行うにあたり、ファインチューニングを行なった。ファインチューニングでは、UNIQLO の EC サイト[15]からスクレイピングにより取得したデータを利用した。以下に取得したデータを示す。

表 5-3：ファインチューニングに用いたデータ

取得方法	Web スクレイピング
件数	15786 件
星の内訳	星 5：9746 件, 星 4：4306 件, 星 3：1015 件, 星 2：344 件, 星 1：375 件

表 5-2 のデータを 4.3 節で説明した前処理を行い、ファインチューニングを行なった。ファインチューニング後に、東レ提供の口コミデータ 470 件に対し分類予測を行い、東レのラベルとの比較を行なった。比較の結果、470 件のうち 391 件は予測結果とラベルは一致し、79 件は不一致であった。一致した口コミは、BERT-CNN も東レの AI も正確に分類できていると考え、不一致であった口コミに対し、3 名にラベル付を行なってもらいどちらが正確に分類できているかを検証した。以下にその結果を示す。

表 5-4：BERT-CNN と東レ AI の検証結果

依頼者	結果
Player1	79 件中 62 件が BERT-CNN と一致
Player2	79 件中 62 件が BERT-CNN と一致
Player3	79 件中 61 件が BERT-CNN と一致

表 5-3 の検証結果より、不一致であった口コミのうち約 8 割が BERT-CNN の方が正確に分類できていたことが分かった。

5.1.3 考察

表 5-1 から分かるように、BERT と BERT-CNN は深層学習系のモデルであることもあり、ロジスティック回帰と比較してかなり AUC が高く、高い精度で分類できることが分かった。BERT と BERT-CNN を比較すると、AUC の平均に関しては、ほとんどの企業で BERT-CNN の方が少し精度が高い結果となり、AUC の分散に関しては、BERT-CNN の方が圧倒的に小さくなった。つまり、BERT-CNN の方が BERT よりも、安定して精度の高い分類ができると考えられる。BERT で文章全体における特徴を掴み、CNN によって長文中の短文における局所特徴量を掴むことで、BERT 単体よりも安定した分類を行うことができると考える。ベルメゾンに関して、BERT の方が精度が高くなったことの原因としては、データ数が少なく、局所特徴を掴むことができていないということが考えられる。

また、BERT-CNN と東レで利用されている AI を比較すると、BERT-CNN の方が正確にラベル付することができることが示された。ファインチューニング後の BERT-CNN の重みを保存しておくことで、新たな口コミに対し簡単に正確なポジティブ・ネガティブの分類を行うことができる。口コミのラベル付を正確に行うことは、口コミ分析を行う上で必要不可欠である。従って、BERT-CNN が既存の AI よりも高精度に口コミ分類ができることを示したことは、非常に有効であると考えられる。

5.2 インナーの市場分析

本節では、目的の一つであるインナーの市場分析を行った結果を示す。まず、収集した 4 社の口コミから各企業の強み・弱みを把握した。そしてその強み・弱みを基に行なったアンケート結果から顧客の潜在ニーズの発掘を行なった。

5.2.1 強み・弱み分析

まず、4 社それぞれの企業の口コミに対し、名詞を抽出し、TfidfVectorizer によって tf-idf の値を基にしたベクトル変換を行った。そしてそのベクトルをロジスティック回帰によってポジティブ・ネガティブの分類ができるように学習させた。学習したロジスティック回帰モデルの絶対値の大きな偏回帰係数を見ることで、ポジティブに大きく影響を及ぼす変数、またネガティブに大きく影響を及ぼす変数（単語のベクトル）を抽出することができる。その変数を強み・弱みと定義し、各企業の強み・弱みを抽出した。以下にそれぞれの企業の、絶対値の大きい偏回帰係数の上位 20 個の変数を示す。

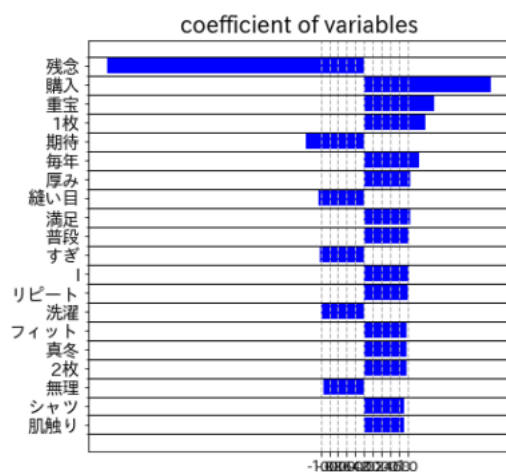


図 5-1 : UNIQLO の偏回帰係数

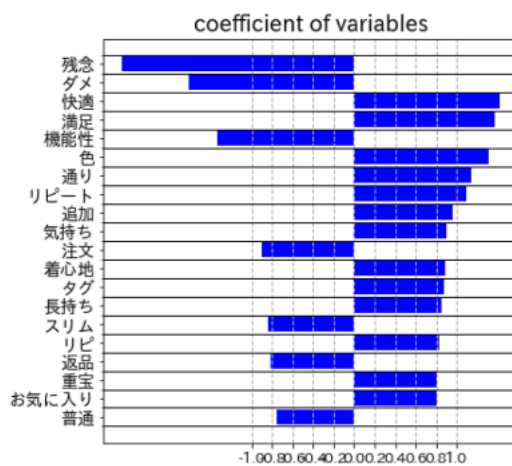


図 5-2 : GUNZE の偏回帰係数

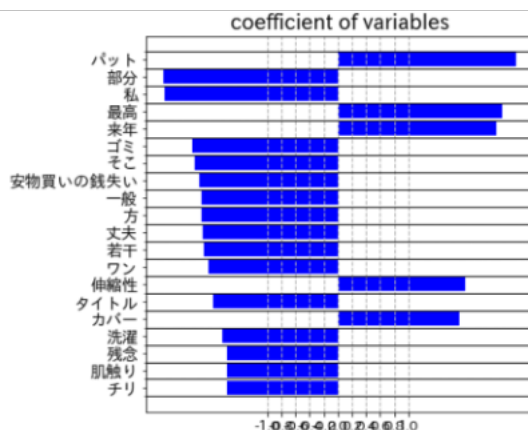


図 5-3 : ベルメゾンの偏回帰係数

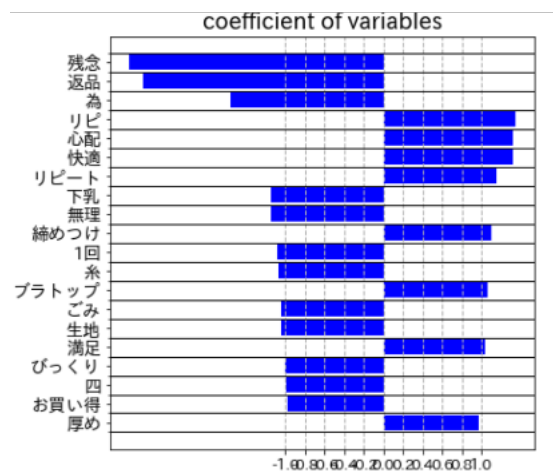


図 5-4：ニッセンの偏回帰係数

真ん中より右に棒が伸びていれば伸びているほど、ポジティブに影響する単語を示し、左に伸びていれば伸びているほど、ネガティブに影響する単語であることを示している。ただし、この偏回帰係数の値は実行ごとに変化するため、10 回分析を行い頻繁に出てくる単語を各企業の強み・弱みとすることとした。以下に各企業の強み・弱みをまとめた結果を示す。

表 5-5：各企業の強み・弱み

企業名	強み	弱み
UNIQLO	肌触り，厚み	洗濯，縫い目
GUNZE	色，着心地，長持ち，タグ	機能性，パット
ベルメゾン	パット，伸縮性	肌触り，洗濯
ニッセン	締め付け，厚め	糸，生地

表 5-4 より、各企業の特徴を掴むことができた。GUNZE におけるパットは、女性用下着の胸部分におけるパットで、ベルメゾンにおけるパットは脇部分におけるパットのことを示している。この各企業の強み・弱みから、アンケート項目を作成し、顧客満足度調査を行なった。

5.2.2 アンケート調査分析

表 5-4 の各企業の強み・弱みからアンケート項目を作成した。その項目を民間企業に委託してアンケートを実施した。以下にアンケート項目と今後の各項目の表示形態を示す。

表 5-6: アンケート項目

質問項目	表示形態
あなたの年代をお答えください	年代
あなたの性別をお知らせください	性別
このインナーは通気性が良い.	通気性
このインナーは汗をよく吸収する.	吸汗性
このインナーのタグは気にならない.	タグ
このインナーは速乾性が高い.	速乾性
このインナーは伸縮性が高い.	伸縮性
このインナーは肌ざわりが良い.	肌触り
このインナーの厚みはちょうど良い.	厚み
このインナーの生地はあなたに適している.	生地
このインナーの機能（基本機能以外の機能）はあなたの期待を満たしている.	機能
このインナーの縫い目はほつれにくい.	縫い目
このインナーは洗濯に強い.	洗濯
このインナーのフィット感はちょうど良い.	フィット感
このインナーブランドは色のバリエーションが豊富である.	色バリエーション
このインナーに満足している.	満足度

アンケート結果のうち全ての項目で同じ数値を選んだ人のデータは、不適当なデータと見なし削除した。このアンケートデータを用いて基礎集計を行なった。データ件数は、1123 件であった。年代、性別、満足度の割合と各項目間の相関係数のヒートマップを以下に示す。




図 5-5：男女別件数

図 5-5 に示すように、男性の方が女性よりも少し多いアンケートデータであった。




図 5-6：年代別件数

図 5-6 より、40 代と 50 代のデータが非常に多く、反対に 10 代から 20 代のデータが非常に少ない結果となった。従って今回のアンケートデータは年配の方の意見が大きく反映されていると考えられる。




図 5-7：満足度の割合

図 5-7 より，満足度は 4, 5, 6 が多く，満足している人が多い分布となっている．今回の分析では，満足度が 1, 2, 3, 4 の人を満足度が低めの人，満足度が 6, 7 の人を満足度が高めの人と定義し，二値分類の分析を行うこととした．




図 5-8：相関係数のヒートマップ

図 5-7 より各変数同士の相関が高めであることが見て取れる．従って分析を行うにあたって変数を選択することは重要である．そこで，ロジスティック回帰分析による推計結果を用いた．そして，偏回帰係数の優位性を確かめるために p 値を算出し，p 値が 5 % の優位水準を満たしている変数を係数が 0 であるとは言えない変数として選択することとした．以下に優位水準を満たした変数と p 値を示す．

表 5-7：優位水準を満たした変数

変数名	p 値
タグ	0.005
機能	0.000
耐久性	0.000
洗濯	0.005
フィット感	0.000

この 5 つの変数を説明変数として，満足度を目的変数としてロジスティック回帰分析による分析を行い，偏回帰係数を可視化した図を以下に示す．




図 5-9：偏回帰係数の可視化結果

図 5-8 より，フィット感が最も満足度の向上に影響が大きく，続いて機能，耐久性，タグ，洗濯が満足度向上への影響が大きいことが示された．次に XGBoost による分析を行い，特徴量重要度を可視化した図も以下に示す．




図 5-10：特徴量重要度の可視化結果

図 5-9 より、フィット感が最も特徴量として重要で、フィット感に続き、機能、耐久性、タグ、選択が重要であることが示された。

5.2.3 考察

表 5-4 より、ロジスティック回帰の偏回帰係数を比較することで、各企業の強み・弱みを抽出することができた。そこからアンケートを実施し、アンケート結果の分析を行い、どの変数が満足度への影響が大きいのかを調査した。図 5-8, 5-9 を比較すると、ほとんど同じ結果が得られていることが分かった。ロジスティック回帰の偏回帰係数は、その特徴量が目的変数に与える効果を意味しているのに対し、XGBoost の特徴量重要度が大きいということは、その変数を使ってノードを分割すると不純度が大きく減少するという意味しており、意味合いが異なってくる。しかし、双方でほとんど同じ結果が得られているということは、その変数が満足度を求める上で重要な変数であることが示されていると考えられる。従って、インナーの顧客満足度を高める上で最も重要な因子は、インナーのフィット感であると言えると考えられる。ただし、この 5 つの変数は、いずれも p 値が 5% の優位性を満たしている変数であるため、全て重要な因子であると考えられる。よって、インナーの顧客の潜在ニーズは、インナーのフィット感、インナーの機能性、インナーの耐久性、インナーのタグは快適である、インナーは洗濯に強い、の 5 つであると結論づけられる。

この分析を通して、問題点も見つかった。一つ目は、データの少なさによる分析結果の揺らぎである。口コミのネガティブデータが少ないことにより、ポジティブデータの数でネガティブデータに合わせるために、ランダムにサンプリングを行っており、この際にどの口コミが選ばれ

るかによって、各企業の強み・弱みが変わってしまう。より多くの口コミデータを収集できれば、揺らぎを減少させることができると考えられる。

2点目は、アンケート結果の各変数の相関が非常に高い点である。アンケートの各変数の VIF を算出した。VIF とは、重回帰分析などの多変量解析で多重共線性を評価する際の指標である。この VIF が非常に高い数値になっており、VIF が 10 以下の変数に絞ろうとすると、変数が一つまで減ってしまい、単回帰で満足度を予測できてしまうという結果になってしまった。よって今回の分析では、p 値の優位性のみにより変数選択を行なっているため、多重共線性を完全に考慮できていないという問題点がある。

3点目は、アンケート対象者の年代に偏りがあった点である。図 5-6 より、40 代、50 代のアンケートが多い結果となっており、若者の潜在ニーズは掴めていないと考えられる。若者のニーズをつかむ場合には、アンケート対象者を若者に絞って分析を行うことが必要であると考えられる。

6. 結論

本章では、本研究の結論、今後の展望について述べる

6.1.1 本研究の結論

本研究では、インナーの口コミ感情分類精度の向上と、インナーの市場分析という2軸の実験・分析を行なった。口コミ感情分類精度の向上に関しては、BERT-CNN という BERT と CNN を組み合わせたモデルを利用することで、文章の全体特徴と局所の特徴双方を正確に掴むことで、他の手法よりも正確に感情分類を行うことができた。さらに、東レで利用している AI と比較しても、より正確に分類できており、実際の現場で用いる有用性を示せた。

インナーの市場分析に関しては、単語を tf-idf を元にしたベクトル化を行い、ロジスティック回帰分析を行うことで、各単語ベクトルの偏回帰係数を求めた。そして偏回帰係数の絶対値が大きい順に並べ抽出することで、各企業の強み・弱みを特定した。口コミから各企業の強み・弱みを特定することができることを示すことができた。その強み・弱みからアンケート項目を作成し、アンケート結果の分析を行うことで、インナーの満足度に影響の大きい因子を特定した。中でも、インナーのフィット感が最もインナーの満足度に重要であることを示すことができた。この結果は、今後の新たなインナーを開発する際の一助となると考える。

6.1.2 今後の展望

インナーの口コミ感情分類精度の向上に関しては、更なる向上が期待できると考える。BERT と CNN 以外の手法の組み合わせや、BERT と同じく Transformer をベースとした GPT-3 を基とした手法を考案し、精度向上することは可能であると考えられる。

また、インナーの市場分析に関しては、より多くのデータを収集することができれば、より正確な各企業の強み・弱みや、顧客の潜在ニーズを掴むことができると考える。また、現状インナーのフィット感が満足度向上に重要であるといった抽象的な結論を導いているが、フィット感とは具体的に何を表しているのかの分析を進めていけば、分析対象企業に更なる提案を行うことができると考える。例えば、素材のデータに対しての分析を進めていけば、この素材はフィット感が良くなる傾向にある。サイズのデータに対して分析を進めていけば、どのサイズを S, M, L サイズにすれば良いなどの提案ができるのではないかと考える。

また、分析の対象者に関しても、現在は、40 代以上の年配の方が多いデータを利用して分析を行なったが、若者のニーズを掴みたい場合には、若者を中心としたアンケートを実施の実施や、Twitter から口コミを収集し分析するといったことを行えばよいと考えられる。分析を進め、より具体的なインナー商品の提案まで落とし込むことが今後の展望である。

7. 謝辞

本論文の制作にあたり，指導教員である鈴木秀男先生には日頃から多くのご指導をいただきましたことを心より感謝申し上げます。また，同研究室の先輩方，並びに共に研究に励んだ同期には研究の面のみならず，様々な面において大変お世話になりました。さらに，本研究で用いたデータを提供してくださった東レ株式会社，サポートしてくださった全ての皆様に深く感謝申し上げます。

8. 参考文献

- [1] “ロコミサイト・インフルエンサーマーケティングに関するアンケート結果”. https://www.caa.go.jp/policies/policy/consumer_policy/policy_coordination/internet_committee/pdf/internet_committee_180927_0003.pdf (accessed Dec. 26, 2022)
- [2] “日本ネット経済新聞 | ユニクロ, 国内 EC 売上は 17.9%増の 1269 億円 OMO 加速で EC 化率は 15.1%に, グローバル EC 売上は 3800 億円に”. <https://netkeizai.com/articles/detail/4826>(accessed Dec. 26, 2022)
- [3] “2022 年版 インナーウェア市場白書”. https://www.yano.co.jp/market_reports/C64106800(accessed Dec. 26, 2022)
- [4] “日本ネット経済新聞 | 「トリンプ」, コロナでブラ需要が二極化 EC 化率は 15%に”. <https://netkeizai.com/articles/detail/4422>(accessed Dec. 26, 2022)
- [5] “下着・靴下業界 市場規模・動向や企業情報”. https://www.nikkei.com/compass/industry_s/0355(accessed Dec. 29, 2022)
- [6] “グンゼの特徴とおすすめルームウェア”. <https://fashion.pintoru.com/room-wear/gunze/>(accessed Dec. 29, 2022)
- [7] 近江崇宏, 金田健太郎, 森長誠, 江間見亜. “BERT による自然言語処理入門”. ストックマーク株式会社. 2021
- [8] Andreas C. Muller, Sarah Guido. “Python ではじめる機械学習”. 株式会社オライリージャパン. 2017
- [9] 門脇太輔, 阪田隆司, 保阪桂佑, 平松雄司. “Kaggle で勝つデータ分析の技術”. 技術評論社. 2019
- [10] Marzieh Mozafari, Reza Farahbakhsh, and Noel Crespi. (2019) “A BERT-Based Transfer Learning Approach for Hate Speech Detection in Online Social. Media”.
- [11] Devlin, J., Chang, M., Lee, K., et al.: (2018) “BERT: pre-training of deep bidirectional transformers for language understanding”.
- [12] Yunchao Wei, Wei Xia, Min Lin, Junshi Huang, Bingbing Ni, Jian Dong, Yao Zhao, Senior Member, IEEE, Shuicheng Yan, Senior Member, IEEE(2016) “HCP: A Flexible CNN Framework for Multi-Label Image Classification”.
- [13] Sandro Sperande. (2013) ”Understanding logistic regression analysis”.
- [14] Chen, T., He, T. (2015) “XGBoost: Extreme gradient boosting”.

- [15] “ユニクロ公式オンラインストア”. <https://www.uniqlo.com/jp/ja/women>(accessed Oct. 1, 2022)
- [16] “グンゼ(GUNZE) -オンライン通販サイト”. <https://www.gunze.jp/store/default.aspx>(accessed Oct. 1, 2022)
- [17] “ファッション通販【ニッセン】”. <https://www.nissen.co.jp/>(accessed Oct. 10, 2022)
- [18] “アマゾン公式サイト”. <https://www.amazon.co.jp/>(accessed Oct. 10, 2022)